

Predição de Variáveis Dinâmicas no Modelo de Sznajd em Redes Complexas

Vítor Amorim Fróis

Resumo

O presente trabalho utiliza Aprendizado de Máquina para prever variáveis complexas no modelo de Sznajd em Redes Complexas: o Tempo de Consenso e a Frequência de Troca de Opinião. Ao utilizar medidas topológicas para caracterização de redes e consequentemente como *features* de rede, podemos prever as variáveis com alta acurácia. Explorando a convergência entre estrutura e dinâmica de redes, esse projeto responde dúvidas relacionadas aos mecanismos de polarização em interações sociais e abre caminho para novos questionamentos. O código do projeto pode ser encontrado no Repositório Sznajd Networks [1].

Conteúdo

1	Introdução	2
2	Materiais e Métodos	3
2.1	Geração de Redes Aleatórias	3
2.1.1	Erdos-Renyi (ER)	3
2.1.2	Small-World de Watts e Strogatz	3
2.1.3	Redes Livre de Escala de Barabási e Albert	3
2.1.4	Redes Geográficas	4
2.2	Simulação de Monte Carlo do modelo de Sznajd	4
2.2.1	Variáveis dinâmicas de interesse	4
2.2.2	Inicialização dos nós	5
2.3	Caracterização de Redes	5
2.3.1	<i>Closeness Centrality</i>	6
2.3.2	Coefficiente de <i>Clustering</i>	6
2.3.3	Entropia de Shannon	6
2.3.4	Assortatividade	7
2.4	Aprendizado de Máquina	7
2.4.1	Coefficiente de Determinação (R ²)	7
2.4.2	<i>Forward Selection</i> (FS)	7
2.4.3	Validação Cruzada	8
2.4.4	Regressão não Linear	8
2.4.5	Normalização dos Dados	8
2.4.6	Random Forests	8
3	Resultados	9
3.1	Predição de Variáveis Dinâmicas	9
3.2	Importância de Features em Random Forests	9
3.3	Análise das <i>features</i> utilizando Regressão não Linear e <i>Forward Selection</i>	9
4	Conclusão	11
5	Referências	13

A	Apêndice	14
A.1	Tabelas de Resultados para Regressão não Linear	14
A.1.1	Tempo de Consenso	14
A.1.2	Frequência de Troca de Opinião	14
A.2	Análise do Tempo de Consenso em Redes Erdos-Renyi com p variável	15

1 Introdução

A interação entre componentes de um sistema que possuem regras simples pode levar a formação de padrões complexos e características como emergência, livre de escala e heterogeneidade. Fenômenos emergentes são presentes em sistemas complexos e caracterizados pelo resultado espontâneo da interação entre os milhares de componentes que constituem o sistema. Um grande exemplo de emergência ocorre durante a noite do sudeste asiático, quando vagalumes da região ajustam a frequência do piscar de suas luzes de acordo com os vizinhos mais próximos, até que o efeito seja estendido por todo o sistema, fazendo que todos vagalumes pisquem em sincronia[2].

No contexto de dinâmicas sociais, isto é, modelos matemáticos que buscam reproduzir o comportamento humano em redes, a emergência pode ser caracterizada como um fenômeno relacionado a polarização [3]. Aqui e no restante do relatório, definimos polarização como a fragmentação de opiniões, um estado contrário ao consenso. Diversos estudos mostram que a polarização pode ter profunda influência no âmbito político, como visto nas manifestações anti-democráticas e violentas ocorridas em Brasília no dia 8 de Janeiro de 2023 [4], [5]. Dessa forma, é de suma importância estudar a polarização para evitar que cenários de discórdia se repitam.

A física estatística desenvolveu ferramentas para o estudo de sistemas de muitas partículas interagentes, os quais são adaptados com facilidade para o estudo de dinâmicas sociais. Erstnt Ising encontrou a solução exata para um modelo de paramagneto, representando materiais que podem alcançar dois estados conflitantes e buscam um estado de mínima energia. O modelo recebeu o nome de Ising e pode ser considerado como um modelo para opiniões binárias, onde há uma transição de fase entre os estados de polarização e consenso. O modelo de Sznajd foi inspirado por Ising e busca explorar como opiniões semelhantes são necessárias para influenciar outros. Já o modelo votante ilustra como a maioria pode influenciar vizinhos, explorando por sua vez como a ordem emerge a partir da opinião maioria.

Para uma compreensão mais realista do fenômeno do consenso, é crucial simular esses modelos em diferentes topologias de rede, uma vez que ela desempenha um papel fundamental na dinâmica do consenso e na polarização resultante. Estudos recentes destacam a influência significativa da topologia da rede nos resultados de consenso e polarização [6]. Dada a significativa influência da topologia da rede na formação de consenso, surge a necessidade de explorar a viabilidade de um modelo de Aprendizado de Máquina para prever variáveis dinâmicas de sistemas complexos com base nas propriedades de rede subjacente. Essa abordagem, amplamente aplicada em campos como sincronização e disseminação de epidemias [7], levanta a questão sobre sua aplicabilidade no estudo do modelo de Sznajd. Este trabalho investiga essa possibilidade, focando na capacidade do aprendizado de máquina de antecipar variáveis dinâmicas do modelo de Sznajd, com base na topologia da rede. Destaca-se assim, o potencial dessas análises de rede para a compreensão de sistemas dinâmicos, fornecendo *insights* valiosos sobre a emergência e evolução da polarização na sociedade.

Esse trabalho proporciona um melhor entendimento na relação entre topologia de rede e dinâmicas sociais, destacando o potencial do uso de métricas de rede para análise de sistemas dinâmicos. Visto a alta colinearidade nas métricas de caracterização (ver Figura 4) e comportamento das variáveis resposta, uma metodologia baseada em *Forward Selection* e Regressão não Linear foi proposta, garantindo alta acurácia, robustez e maior explicabilidade em relação a improntância de *features* das *Random Forests*.

2 Materiais e Métodos

2.1 Geração de Redes Aleatórias

Seis diferentes topologias das redes foram examinadas. As redes Erdős–Rényi, Barabási–Albert linear, Barabási–Albert não linear com $\alpha = 0.5$ and $\alpha = 1.5$, Watts–Strogatz e Waxman [8], [9]. Essas topologias buscam abordar diferentes estruturas que sociedades reais possam admitir, considerando a presença de hubs, comunidades e *small-world*. Ou seja, como as redes geradas por esses modelos apresentam diferentes propriedades que podem ser controladas através de seus parâmetros, poderemos gerar um banco de dados com exemplos de topologias diferentes. Assim, os efeitos de propriedades topológicas no processo dinâmico podem ser verificados, visto que muitas propriedades, como distância entre os vértices ou nível de centralidade, sofrerão variações nas bases geradas. Essa variação é importante para oferecermos exemplos diferentes aos modelos de aprendizado que usaremos na fase de predição das variáveis dinâmicas. Para cada uma dessas redes, 100 instâncias foram criadas visando diminuir efeitos da aleatoriedade na construção do modelo.

2.1.1 Erdos-Renyi (ER)

O modelo de Erdos-Renyi (ER) é um dos mais estudados e detalhados na teoria dos grafos. É formado ao ligar N nós entre as possíveis arestas com probabilidade p . Apesar de não representar com fidelidade cenários do mundo real, possui apelo matemático por possuir características bem definidas.

2.1.2 Small-World de Watts e Strogatz

Diversas redes do mundo real exibem a propriedade *small-world*, isto é, a maioria dos vértices podem ser alcançados pelo restante a partir de um pequeno número de arestas. Essa propriedade é muito comum em redes sociais.

Outra propriedade muito relevante em redes é a presença de *loops* de tamanho três: se i está conectado a j e k , há uma grande probabilidade que j e k estejam conectados por sua vez. As redes ER possuem característica de pequeno mundo, porém não apresentam muitos triângulos. De forma contrária, é fácil construir redes com abundância de loops, mas é difícil garantir a presença de características de pequeno mundo.

O modelo mais popular que uniu as duas características foi desenvolvido por Watts e Strogatz e recebeu o nome de modelo *small-world* de Watts-Strogatz (WS). Para construí-lo, comece com uma grade triangular e realize a reconexão de cada aresta presente com probabilidade p . Para $p \approx 0$, a rede original é mantida, enquanto que para $p \approx 1$ há uma rede aleatória.

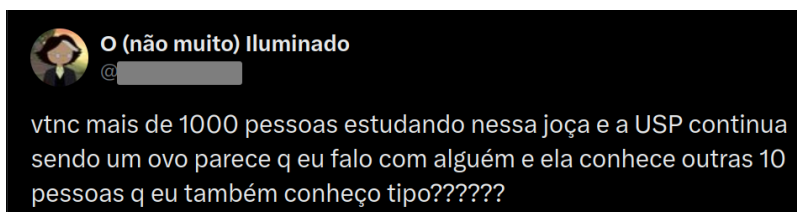


Figura 1: Post na plataforma X (Twitter) discute sobre a rede de interações da Universidade de São Paulo, a qual possui características estudadas por Watts e Strogatz. Fonte: [10]

2.1.3 Redes Livre de Escala de Barabási e Albert

Barabási e Albert demonstraram que a distribuição do grau de inúmeros sistemas do mundo real é caracterizada por uma distribuição assimétrica. Nessas redes, alguns vértices são altamente conectados enquanto outros possuem poucas conexões. Uma característica muito importante dessa rede é a existência de *hubs*, vértices que são conectados a uma fração significativa do total da rede. A construção das redes Barabási–Albert inicia com um conjunto de vértices e iterativamente adiciona arestas de forma que os vértices mais conectados possuam maior chance de formar novas arestas. Esse processo leva a formação de uma rede onde a distribuição dos nós segue uma lei de potência.

2.1.4 Redes Geográficas

A maioria das redes complexas mora em um espaço abstrato, onde a posição dos vértices não tem um sentido particular. Em algumas redes, porém, a posição dos vértices pode ter importante impacto, como por exemplo, no caso de redes de transporte rodoviário, aéreo e redes neuronais. Esses exemplos recebem o nome de redes geográficas. Uma maneira simples de gerar redes geográficas é distribuir N vértices em um espaço abstrato e conectá-los com uma probabilidade que decai de acordo com a distância entre eles.

2.2 Simulação de Monte Carlo do modelo de Sznajd

O modelo de *spin* de Ising é um dos modelos mais utilizados na mecânica estatística [11]. No artigo [12] é proposto o modelo de Sznajd, uma adaptação de Ising para descrever dinâmicas de opinião em uma comunidade.

O modelo original segue uma simulação estocástica implementando o fenômeno de validação social nos agentes $S_i, i = 1, 2, \dots, N$ com opiniões $O = \{-1, +1\}$. A cada passo, dois vizinhos são selecionados e o sistema é atualizado de acordo com as seguintes regras dinâmicas:

- Se $S_i S_{i+1} = 1$, então os vizinhos S_{i-1} e S_{i+2} recebem a opinião do par S_i, S_{i+1} ;
- Se $S_i S_{i+1} = -1$, então $S_{i-1} = S_{i+1}$ e $S_{i+2} = S_i$

O modelo original foi proposto para um sistema unidimensional. No entanto, a dinâmica foi modificada de forma incluir uma rede complexa [13]. Nesse trabalho será utilizada a adaptação apresentada em [14] para implementação do modelo de Sznajd em redes com duas opiniões. Considere uma rede de N pessoas, com opiniões $O = \{-1, +1\}$ inicialmente distribuídas de forma aleatória. Cada indivíduo é uma variável dinâmica binária $s(x, t) = O$ de grau k_x , em que $x = 1, \dots, N$. Uma iteração t de uma sequência de iterações até o consenso é descrita abaixo:

- Uma dupla de nós vizinhos i e j é escolhida aleatoriamente;
- Se $s(i, t) \neq s(j, t)$ a iteração termina;
- Se $s(i, t) = s(j, t)$, a união dos vizinhos de i e j recebe a opinião de i .

2.2.1 Variáveis dinâmicas de interesse

O **tempo de consenso**, definido como o período necessário para que o sistema alcance um estado estacionário, é uma métrica crucial na análise da dinâmica de consenso, bem como a **frequência da troca de opinião**. Durante a simulação, registramos tanto o tempo de consenso quanto a frequência de troca de opinião como indicadores-chave do comportamento do sistema. O histograma de ambas variáveis aleatórias são exibidos abaixo com a estimativa de densidade correspondente nas figuras 2 e 3. Se faz necessária a utilização da escala logarítmica para visualização devido ao aspecto de cauda pesada das distribuições.




Figura 2: Histograma do Tempo de Consenso na escala logarítmica




Figura 3: Histograma da Frequência de Troca de Opinião na escala logarítmica

2.2.2 Inicialização dos nós

Os parâmetros para as redes e o modelo foram fixados para proporcionar um patamar conciso durante os testes com os algoritmos de aprendizado de máquina. Ao fixar esses parâmetros é possível focar no impacto de outras variáveis na análise. Dessa forma, as simulações contarão com as redes com um número de nós fixo, a saber, $N = 1000$, além de uma porcentagem de nós com opiniões positivas $p = 0, 2$.

Além disso, adotamos três abordagens distintas de inicialização para os nós com opiniões positivas nas simulações. Primeiramente, a inicialização aleatória, atribuindo aleatoriamente opiniões positivas aos nós. Em seguida, adotamos a estratégia de inicialização inversa, na qual os nós com menor grau receberão opiniões positivas. Por fim, aplicaremos a inicialização direta, na qual os nós mais influentes na rede receberão opiniões positivas. É de suma importância simular o sistema com diferentes inicializações, possibilitando analisar como a importância das *features* são influenciadas em cada caso e compreender melhor como situações de consenso podem ser favorecidas.

2.3 Caracterização de Redes

Buscamos caracterizar cada rede i utilizando um vetor de *features* derivado de sua estrutura e denotado por $X_i = \{X_{i1}, X_{i2}, \dots, X_{ik}\}$, em que X_{ik} é a k -ésima métrica da rede i . Assim, foram utilizadas diversas medidas, incluindo o coeficiente de *clustering*, *closeness centrality*, *betweenness centrality*, *average shortest path length*, coeficiente de correlação de Pearson do grau, *information centrality*, *approximate current flow betweenness centrality* e *eigenvector centrality*, entropia de Shannon e variância do grau. Tais medidas, usadas coletivamente aqui, fornecem *insights* valiosos sobre a topologia, conectividade, eficiência, influência e organização em redes complexas [9].

As métricas descritas acima são divididas entre três grandes grupos, sendo eles medidas de centralidade (*closeness centrality*, *betweenness centrality*, *average shortest path length*, *information centrality*, *approximate current flow betweenness centrality* e *eigenvector centrality*), de transitividade (*clustering*) e de conectividade (assortatividade, entropia de Shannon e variância do grau). Podemos obter um *heatmap* entre as *features* obtidas para as redes geradas utilizando a correlação de Spearman, uma medida que quantifica a colinearidade entre duas variáveis. Ao analisar o *heatmap*, vemos que há grande correlação linear entre diversas *features*, principalmente aquelas que pertencem aos mesmos grupos. Esse resultado é importante pois quando há informação mútua entre variáveis, o grau de influência no resultado de modelos de Aprendizado de Máquina é diluído.

A seguir, realizamos uma revisão das métricas de rede mais importantes para compreensão desse trabalho.




Figura 4: *Heatmap* utilizando correlação de Spearman entre as *features*. As colunas estão ordenadas como as linhas. A cor vermelha indica coeficiente de Spearman 0 e, portanto, baixa colinearidade. De forma contrária, valores muito claros ou muito escuros indicam colinearidade entre as métricas para as redes geradas. Assim, é possível observar alta colinearidade entre diversas *features*.

2.3.1 Closeness Centrality

Em redes, quanto mais próximo a outros um vértice está, maior a sua importância na rede. Assumindo que as interações entre nós seguem o caminho mais curto, a *Closeness Centrality* de um nó u é definida como o recíproco da distância do caminho mais curto entre u e os outros $n - 1$ nós da rede $v = 1, \dots, n$.

$$CC(u) = \frac{n - 1}{\sum_v d(u, v)}.$$

Onde $d(u, v)$ é a distância do caminho mais curto entre v e u . Quanto maior o valor de *Closeness*, maior a importância do vértice na rede. Para caracterizar a rede foi utilizada o *Closeness* médio dos nós.

2.3.2 Coeficiente de Clustering

Uma maneira simples de caracterizar a presença de *loops* de tamanho três é através do coeficiente de *Clustering*.

$$C = 3 \frac{\text{\#triângulos}}{\text{\#triádes}}.$$

O fator 3 leva em conta que cada triângulo pode ser parte de três triplas diferentes, cada uma com um vértice sendo o principal e garante que $C \in [0, 1]$.

2.3.3 Entropia de Shannon

Entropia é um conceito chave em termodinâmica, mecânica estatística e teoria da informação. Está relacionada fisicamente com a quantidade de desordem e informação presentes em um sistema. Na teoria da informação, entropia descreve quanta aleatoriedade está presente em um evento aleatório. No contexto de redes complexas, o conceito de entropia pode ser aplicado ao calcular a entropia da distribuição de probabilidade do grau dos nós na rede. Essa medida provê uma média de heterogeneidade da rede e pode ser definida como

$$H = - \sum_k P(k) \log P(k).$$

O valor máximo de entropia é obtido para uma distribuição uniforme quando todos vértices possuem o mesmo grau e está relacionada com a robustez e resiliência da rede.

2.3.4 Assortatividade

Uma característica muito importante em redes é a presença de conexões homogêneas. Podemos nos perguntar, por exemplo, quão provável é a conexão entre nós similares. A assortatividade mede a similaridade de conexões no grafo com respeito ao grau do nó. Quando vértices de alto grau tendem a se conectar com vértices de alto grau, a rede é assortativa. Por outro lado, se os vértices de alto grau se conectam a vértices de baixo grau a rede é disassortativa.

O cálculo da assortatividade é feito através do Coeficiente de Correlação de Pearson r . Caso $r > 0$, a rede é assortativa; se $r < 0$, a rede é disassortativa; para $r = 0$ não existe relação entre o grau dos vértices.

2.4 Aprendizado de Máquina

Nesse trabalho assumimos que o tempo para alcançar consenso Y_i e a frequência de mudança de opinião C_i podem ser inferidos a partir do vetor de *features* X_i . A explicação abaixo foca na predição de Y_i mas também é válida para C_i .

$$Y_i = f(X_i) + \delta.$$

Nosso objetivo é encontrar a função f que relaciona Y_i às métricas da rede. Trataremos predição de Y_i como um problema de regressão em que δ é um termo que representa uma distribuição normal com média zero e desvio padrão σ . Esse termo representa a incerteza nos dados, que incluem as medidas que não foram incluídas no modelo e as flutuações aleatórias na simulação das redes e modelos.

2.4.1 Coeficiente de Determinação (R^2)

O coeficiente de determinação, R^2 , é uma métrica usada para medir o quão bem um modelo de regressão se ajusta aos dados [15] e é definido como:

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

Para cada amostra i , y_i é o valor real, \hat{y}_i é o valor predito e \bar{y} é a média dos valores reais. Um valor de 1 significa que o modelo realiza predições perfeitas. De forma contrária, um valor igual ou menor a 0 indica que o modelo não possui habilidade de predição.

No entanto, quando adicionamos mais preditores ao modelo, o R^2 pode aumentar mesmo que esses novos preditores não ajudem realmente a explicar a variação na variável dependente [16], [17]. Para lidar com isso, utilizaremos o R^2 ajustado, que leva em consideração o número de preditores p e penaliza a inclusão daqueles que são irrelevantes. Esse ajuste fornece uma avaliação mais precisa para o resultado previsto para o modelo. Isso garante uma avaliação mais confiável do desempenho do modelo. Na fórmula abaixo, n indica o número de amostras no conjunto.

$$R^2_{\text{adj}} = 1 - \frac{(1 - R^2)(n - 1)}{(n - p - 1)}$$

2.4.2 Forward Selection (FS)

Forward Stepwise Selection é uma maneira eficiente para selecionar *features*, que começa com um modelo sem preditores e adiciona variáveis uma a uma, até que os preditores exigidos estejam no modelo. De modo particular, em cada passo é adicionado o melhor preditor ao modelo. Considerando a alta colinearidade entre

as variáveis explicativas, o FS desempenha um papel muito eficiente ao selecionar a melhor variável em cada passo sem descartar suas correlações [18]. O FS pode ser calculado seguindo o algoritmo:

1. Considere o modelo nulo M_0 , sem variáveis preditoras.
2. Para $k = 0, \dots, p - 1$:
 - a) Considere todos $p-k$ modelos que adicionem uma variável ao modelo anterior M_k
 - b) Escolha M_{k+1} como o melhor entre os $p-k$ modelos
3. Escolha o melhor entre todos modelos M_0, \dots, M_p do passo 2 utilizando uma métrica como R^2

2.4.3 Validação Cruzada

A fim de analisar os resultados, foi utilizado o R^2 no modelo de aprendizado de máquina, juntamente com técnicas descritas acima, como a validação cruzada e etapa de teste em um conjunto oculto de dados. Essa etapa busca garantir que o modelo foi capaz de generalizar com base nos dados de treinamento e consegue realizar boas previsões em dados novos.

A validação cruzada divide o conjunto de treinamento em k -folds de tamanho semelhante. O primeiro *fold* é tratado como conjunto de validação, e o modelo é treinado nos $k-1$ folds restantes. A métrica de avaliação é então computada com as observações de validação e o valor é armazenado. Ao final das k iterações, o valor da métrica é a média de cada iteração [18].

A validação cruzada foi utilizada durante FS e para otimização de hiperparâmetros no treinamento das Random Forests. Para o caso de seleção, as duas *features* mais importantes são aquelas com maior frequência entre todos os k folds.

2.4.4 Regressão não Linear

A Regressão não Linear é apropriada em casos onde a variável resposta não é linear de acordo com as *features* e pode ser realizada através de uma transformação não-linear apropriada [18]. No nosso caso é utilizado o logaritmo e buscamos estimar os coeficientes β_1, \dots, β_p tal que

$$\log(Y_i) = X_i\beta + \delta$$

também pode ser escrito como

$$Y_i = e^{X_i\beta + \delta}$$

A imagem da função exponencial é $(0, \infty)$, garantindo que o valor estimado Y_i sempre será positivo.

2.4.5 Normalização dos Dados

Para análise de regressão, é essencial que os dados estejam normalizados, a fim de impedir o cálculo de coeficientes imprecisos e ajudar a determinar quais variáveis possuem maior importância. Para tanto, basta subtrair os valores pela média e dividir pelo desvio padrão do conjunto de treino. A normalização é efetuada após a transformação logarítmica [18].

$$X_{\text{std}} = \frac{X - \mu}{\sigma}$$

2.4.6 Random Forests

Modelos de aprendizado de máquina robustos para dados tabulares envolvem o *ensemble* de árvores de decisão, em que a resposta final é uma média de cada uma das árvores. Dentre esses modelos, as *Random Forests* se popularizaram ao propor uma construção de árvores através de *bootstrap aggregation* ou *bagging*. Em cada passo, uma árvore é treinada a partir de um conjunto obtido a partir de amostragem com reposição do conjunto de treinamento. Após um grande número de árvores ser gerado, uma nova amostra é predita a partir das médias dos valores de todas as outras árvores [19].

3 Resultados

3.1 Predição de Variáveis Dinâmicas

A Figura 5 apresenta um boxplot com os modelos Random Forest e Regressão não Linear para predição de variáveis dinâmicas. É possível observar que ambos modelos aprendem os dados do conjunto de treinamento, mas o modelo de Regressão não Linear alcança uma generalização levemente melhor. Notavelmente, o segundo modelo possui treinamento mais simples e apresenta maior explicabilidade. Dessa forma, em conjunto com o Forward Selection, se caracteriza como um método para análise topológica da rede, aprofundado na seção 3.3.




Figura 5: Cada coluna representa a distribuição dos valores ajustados de um modelo e conjunto (treino ou teste) para predição das variáveis dinâmicas. É possível observar que ambos modelos aprendem os dados do conjunto de treinamento, mas o modelo de Regressão não Linear (direita) alcança uma generalização levemente melhor em relação as Random Forests (esquerda).

3.2 Importância de Features em Random Forests

Análise das features mais importantes foi feita para ambas variáveis resposta e diferentes métodos de inicialização, demarcados de acordo com as cores. As features estão ordenadas de forma decrescente no gráfico por importância média. É importante notar a diluição da importância das features no Tempo de Consenso, em que há uma grande distinção entre importância para cada inicialização diferente 6. Já na Frequência de Troca de Opinião, a variância do grau é dominante para todas inicializações. De forma contrária, *Eigenvector* e Assortatividade não demonstram nenhuma capacidade preditiva 6. Em todos os casos, não fica claro quais métricas são determinantes para predição das variáveis resposta, reforçando a importância da seleção de *features* nesse cenário.

3.3 Análise das *features* utilizando Regressão não Linear e *Forward Selection*

Os métodos de Regressão com mínimos quadrados nos permitem aprofundar nos resultados para maior interpretabilidade das variáveis resposta através dos coeficientes de regressão, p-valores e outras informações [17]. Aqui, realizamos uma seleção empírica das variáveis da seção 2.3 prezando pela diversidade e explicabilidade. Assim, os próximos resultados advêm do mesmo cenário da subseção anterior considerando apenas as variáveis descritas na seção 2.3: entropia de Shannon, assortatividade, *Closeness Centrality* e coeficiente de *Clustering*.




Figura 6: Importância de *features* para o Tempo de Consenso: há uma diluição de importância entre as *features*. Apesar da entropia apresentar um grande impacto, outras características topológicas também demonstram ter um impacto significativo, tornando a análise mais difícil.




Figura 7: Importância de *features* para a Frequência de Troca de Opinião: a variância do grau tem grande importância nesse cenário, mas ainda é difícil analisar quais *features* podem ser decisivas na determinação da Frequência de Troca de Opinião.

Através das tabelas obtidas para cada uma das variáveis resposta e cada um dos métodos de inicialização, exibidas no apêndice A.1, percebemos pelos baixos valores de p -value e $standard\ error$ que há uma grande significância das *features* selecionadas. Além disso, com apenas duas métricas selecionadas, é possível alcançar um coeficiente de determinação superior a 0.98, como exibido na Figura 5. No caso da Frequência de Troca de Opinião (figura 8), o *Clustering* se apresenta para as três inicializações em uma relação direta: quanto maior o coeficiente, maior a frequência de troca de opinião. É uma medida que aumenta de acordo com o número de triângulos presentes na rede. Dessa forma, é possível supor que a presença de triângulos na rede incita a troca de opiniões entre os indivíduos. Para o Tempo de Consenso (figura 9), pode se observar o *Closeness Centrality* em uma relação inversa com a variável resposta. A *feature* em questão aumenta a medida que a distância média entre os pares de nós na rede diminui. No nosso caso, isso pode indicar que quando, em média, os nós da rede estão mais próximos uns aos outros, menor o tempo necessário para alcançar um consenso na rede.

Finalmente, ao comparar o método proposto com a análise promovida pela importância nas *Random Forests*, percebe-se uma diminuição no espaço de exploração, facilitando a análise e interpretação dos resultados. Além disso, a regressão não linear também apresenta coeficientes explicáveis, permitindo interpretação direta dos resultados. Por exemplo, utilizando as equações da seção 2.4.4 e os resultados de A.1, é possível escrever a Frequência de Troca de Opinião F como a exponencial da combinação linear das *features*.

$$F = \exp(6.48 + clustering \times 1.222 + closeness \times 0.082)$$

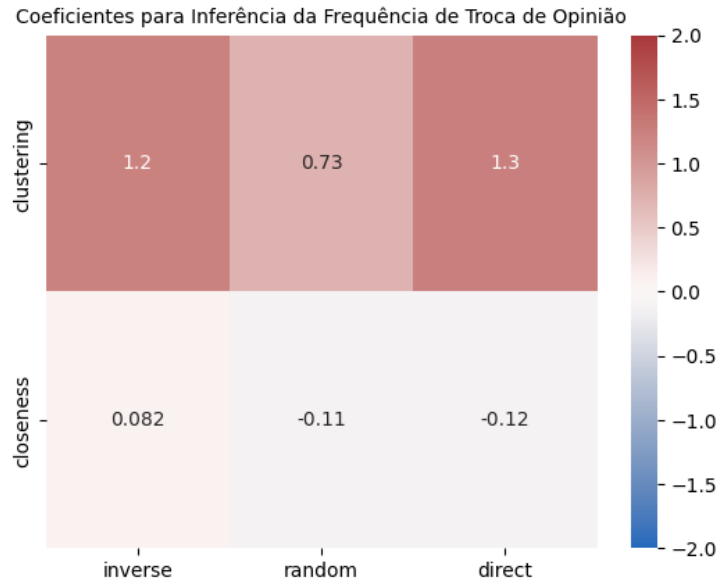


Figura 8: Coeficientes de regressão obtidos para para Inferência da Frequência de Troca de Opinião de acordo com diferentes inicializações.

4 Conclusão

Nesse trabalho, conseguimos prever variáveis dinâmicas associadas com o modelo de Sznajd utilizando métricas de topologia de rede. Verificamos que a predição obteve grande acurácia e propusemos um método para obter maior explicabilidade e semelhante acurácia quando comparado a *Random Forests*. Assim, conseguimos verificar não apenas quais *features* são mais importantes na emergência de polarização, mas também qual o nível de influência. Principalmente, mostramos que o coeficiente de *Clustering* e *Closeness Centrality* podem ser utilizado para prever as variáveis dinâmicas associadas as simulações. Além disso, três mudanças nos métodos de inicialização dos nós foram considerados, buscando entender como as medidas




Figura 9: Coeficientes de regressão obtidos para para Inferência do Tempo de Consenso de acordo com diferentes inicializações.

topológicas podem ser influenciadas nesse caso. Inicialmente, os nós foram escolhidos de forma aleatória, seguindo o modelo original de Sznajd. Após, nós com maior grau foram selecionados para investigar como seu grande número de conexões pode influenciar a dinâmica da rede. Por fim, os nós na periferia da rede foram selecionados para entender o impacto de agentes menos influentes. Apesar dessas modificações impactarem o resultado das simulações, conseguimos observar que o impacto é pequeno e as métricas selecionadas se conservam ao longo dos experimentos.

O uso de Random Forests nos permitiu analisar a importância de features, onde foi encontrada uma diluição de importância. Duas features tem comportamento semelhante e impactam a predição de maneira semelhante, o que torna a análise dos dados mais difícil. Tal observação se confirma ao analisar o Heatmap na Figura 9. Assim, o método proposto busca encontrar um subconjunto de *features* que obtenha alta acurácia através de Regressão não Linear, possibilitando análise dos coeficientes. Nesse cenário, os coeficientes de Regressão indicam que a presença de triângulos na rede favorece a troca de opiniões entre os indivíduos e que, em média, quanto menor a distância entre os nós da rede, menor o tempo necessário para alcançar o consenso. Notavelmente, a magnitude de influência de *Closeness Centrality* na predição do Tempo de Consenso aumenta de acordo com o grau dos nós que recebem a opinião predominante, mostrando que a proximidade entre nós é especialmente influente quando os nós dominantes são mais conectados.

No apêndice A.2 são apresentados resultados que motivaram a escrita do projeto de intercâmbio ‘Modelo de Ising em Redes Aleatórias’ e estudos em realização. O projeto de Intercâmbio visa explorar tratamento de campo médio em um modelo mais simples, prevendo possível extensão dos resultados para o modelo de Sznajd. Assim, o projeto de Intercâmbio é de suma importância para continuidade da pesquisa.

A expansão da metodologia proposta para predição e análise de variáveis topológicas além do modelo de Sznajd pode promover novos *insights* relativos a diversos cenários e estudos em dinâmicas sociais. Esperamos que trabalhos futuros nessa direção contribuam para um melhor entendimento de dinâmicas complexas para a polarização e suas implicações. A combinação de aprendizado de máquina com redes complexas tem um grande potencial para revolucionar nossa compreensão de sistemas sociais, levando a um maior entendimento do comportamento e desenvolvimento de estratégias para alcançar resultado social positivo.

5 Referências

- [1] «Repositório SznajdNetworks». <https://github.com/vitorfrois/SznajdNetworks>.
- [2] S. Johnson, *Emergence: The connected lives of ants, brains, cities, and software*. Simon; Schuster, 2002.
- [3] H. P. Maia, S. C. Ferreira, e M. L. Martins, «Adaptive network approach for emergence of societal bubbles», *Physica A: Statistical Mechanics and its Applications*, vol. 572, p. 125588, 2021, doi: <https://doi.org/10.1016/j.physa.2020.125588>.
- [4] R. Interian e F. A. Rodrigues, «Group polarization, influence, and domination in online interaction networks: a case study of the 2022 Brazilian elections», *Journal of Physics: Complexity*, vol. 4, n.º 3, p. 035008, set. 2023, doi: [10.1088/2632-072x/acf6a4](https://doi.org/10.1088/2632-072x/acf6a4).
- [5] M. L. Layton, A. E. Smith, M. W. Moseley, e M. J. Cohen, «Demographic polarization and the rise of the far right: Brazil's 2018 presidential election», *Research & Politics*, vol. 8, n.º 1, p. 2053168021990204, 2021, doi: [10.1177/2053168021990204](https://doi.org/10.1177/2053168021990204).
- [6] A. M. Pineda, P. Kent, C. Connaughton, e F. A. Rodrigues, «Machine learning-based prediction of Q-voter model in complex networks». 2023. Disponível em: <https://arxiv.org/abs/2310.09131>
- [7] F. A. Rodrigues, T. Peron, C. Connaughton, J. Kurths, e Y. Moreno, «A machine learning approach to predicting dynamical observables from network structure». 2019. Disponível em: <https://arxiv.org/abs/1910.00544>
- [8] S. Boccaletti, V. Latora, Y. Moreno, M. Chavez, e D.-U. Hwang, «Complex networks: Structure and dynamics», *Physics Reports*, vol. 424, n.º 4–5, pp. 175–308, 2006.
- [9] L. da F. Costa, F. A. Rodrigues, G. Travieso, e P. R. Villas Boas, «Characterization of complex networks: A survey of measurements», *Advances in Physics*, vol. 56, n.º 1, pp. 167–242, 2007.
- [10] «Print de Tweet». <https://x.com/LuzMadLED/status/1852872862903771258>.
- [11] C. Castellano, S. Fortunato, e V. Loreto, «Statistical physics of social dynamics», *Reviews of Modern Physics*, vol. 81, n.º 2, pp. 591–646, 2009, doi: [10.1103/revmodphys.81.591](https://doi.org/10.1103/revmodphys.81.591).
- [12] K. SZNAJD-WERON e J. SZNAJD, «OPINION EVOLUTION IN CLOSED COMMUNITY», *International Journal of Modern Physics C*, vol. 11, n.º 6, pp. 1157–1165, set. 2000, doi: [10.1142/s0129183100000936](https://doi.org/10.1142/s0129183100000936).
- [13] J. R. Sanchez, «A modified one-dimensional Sznajd model». 2004. Disponível em: <https://arxiv.org/abs/cond-mat/0408518>
- [14] A. T. Bernardes, D. Stauffer, e J. Kertész, «Election results and the Sznajd model on Barabasi network», *The European Physical Journal B - Condensed Matter*, vol. 25, n.º 1, pp. 123–127, jan. 2002, doi: [10.1140/e10051-002-0013-y](https://doi.org/10.1140/e10051-002-0013-y).
- [15] P. Johnson e H. Schielzeth, «The coefficient of determination R² and intra-class correlation coefficient from generalized linear mixed-effects models revisited and expanded», *Journal of The Royal Society Interface*, vol. 14, p. 20170213, set. 2017, doi: [10.1098/rsif.2017.0213](https://doi.org/10.1098/rsif.2017.0213).
- [16] C. M. Bishop, «Pattern recognition and machine learning», *Springer Google Scholar*, vol. 2, pp. 645–678, 2006.
- [17] K. P. Murphy, *Machine learning: a probabilistic perspective*. MIT press, 2012.
- [18] G. James, D. Witten, T. Hastie, e R. Tibshirani, *An Introduction to Statistical Learning: with Applications in R*. Springer Publishing Company, Incorporated, 2014.
- [19] L. Breiman, «Random Forests», *Machine Learning*, vol. 45, pp. 5–32, 2001.

A Apêndice

A.1 Tabelas de Resultados para Regressão não Linear

A.1.1 Tempo de Consenso

Inicialização Aleatória: Adj. R2: 0.988

	Coef	p-valor	Std. error
const	5.937	0	0.004
clustering	0.73	0	0.009
closeness	-0.111	0	0.009

Inicialização Direta: Adj. R2: 0.993

	Coef	p-valor	Std. error
const	6.023	0	0.006
clustering	1.265	0	0.011
closeness	-0.121	0	0.011

Inicialização Inversa: Adj. R2: 0.993

	Coef	p-valor	Std. error
const	6.48	0	0.004
clustering	1.222	0	0.009
closeness	0.082	0	0.009

A.1.2 Frequência de Troca de Opinião

Inicialização Aleatória: Adj. R2: 0.993

	Coef	p-valor	Std. error
const	6.626	0	0.006
clustering	0.316	0	0.012
closeness	-1.265	0	0.012

Inicialização Direta: Adj. R2: 0.991

	Coef	p-valor	Std. error
const	6.793	0	0.01
closeness	-2.271	0	0.013
shannon_entropy	0.146	0	0.013

Inicialização Inversa: Adj. R2: 0.997

	Coef	p-valor	Std. error
const	6.606	0	0.005
clustering	1.208	0	0.01
closeness	-0.835	0	0.01

A.2 Análise do Tempo de Consenso em Redes Erdos-Renyi com p variável

O estudo demonstrou relativa facilidade de predição do Tempo de Consenso para casos gerais. Assim, os testes foram expandidos para analisar o Tempo de Consenso em modelos de rede com parâmetros variados. Nesse sentido, foi feito um experimento considerando redes Erdos-Renyi de tamanho $N = 1000$ e $p \in [0, 1]$. Note que para essas redes, o p coincide com o coeficiente de *Clustering*. A análise dos dados de simulação gerou o gráfico abaixo.




Figura 10: Simulações sugerem uma lei de potência entre o Tempo de Consenso e o coeficiente de *Clustering* nas simulações do modelo de Sznajd em redes Erdos-Renyi com $N = 1000$ e $p \in [0, 1]$

É possível observar uma lei de potência entre as métricas de rede e o Tempo de Consenso. Assim, o projeto de Intercâmbio ‘Modelo de Ising em Redes Aleatórias’ é de suma importância para continuação da pesquisa e visa se aprofundar no tratamento analítico de dinâmicas de opinião buscando compreender melhor e derivar expressões para os modelos estudados.